题目/要求

课题：AI Data Analyst Agent · 复杂数仓环境下的智能分析全链路挑战（公开版）

所属赛道：飞书 AI 校园挑战赛 2026 · 数据分析方向

课题一句话：构建一个 AI Data Analyst Agent，面对一个包含 37 张表、覆盖 8 个业务域的模拟 SaaS 企业数仓，完成从"构建数据知识库 → 读懂表结构 → 多表关联查询 → 错误自修复 → 深度分析洞察"的全链路闭环。

一、课题背景

1.1 数据分析师的真实挑战

企业数据分析师的日常工作，远不是"给一张表做 EDA"。真实场景中，分析师面对的是由**数十甚至上百张业务表**组成的数据仓库——表之间关系错综复杂，字段含义需要经验推断，JOIN 逻辑稍有不慎就会导致数据膨胀或缺失。一个典型的分析需求需要经历：

1. **理解数据全貌**：面对大量表，读懂每张表的业务含义、数据粒度、字段语义
2. **发现关联关系**：判断表之间如何 JOIN——主键/外键、业务键、时间窗口关联等
3. **写出正确查询**：处理多表 JOIN 中常见的粒度不匹配、重复计算、口径不一致问题
4. **分析出错时自修复**：当查询结果异常时，能自主诊断原因并修正
5. **构建可复用的知识**：将对数据的理解沉淀为知识体系，而不是每次从零开始
6. **产出有价值的洞察**：最终交付可驱动业务决策的分析报告

1.2 AI 工具的现状与差距

随着 LLM 和 Agent 技术日趋成熟，"自然语言驱动的数据分析"成为可能。但目前的 Text2SQL / AI 分析工具仍存在明显短板：

- **Schema 理解能力弱**：面对 30+ 张表时，无法准确推断表的业务含义和关联关系
- **JOIN 逻辑容易出错**：粒度不匹配导致数据膨胀，缺少过滤条件导致笛卡尔积
- **缺乏自我纠错能力**：查询出错后只能报错，无法诊断"为什么错了"并自动修复
- **无知识积累机制**：每次分析从零开始，无法从历史分析中沉淀经验

二、能力考察重点

本课题重点考察选手构建 **AI Data Analyst Agent** 的综合能力。我们鼓励具备以下能力与背景的选手参赛：

- 对**数据建模与 SQL** 有扎实理解，能处理多表关联、缓慢变化维度、数据质量等真实问题
- 具备 **LLM / Agent** 应用开发能力，能设计合理的 Agent 工具链和推理链路
- 拥有**产品思维**，能将技术能力转化为用户友好的分析工具
- 对**数据质量与分析方法论**有认知，了解统计检验、归因分析、实验分析等专业方法

三、任务目标与范围

3.1 数据集

组委会提供统一数据集 **「CloudWork」**——一个模拟 SaaS 企业协作平台（类似飞书/Slack/Notion）的完整数据仓库。

- **37 张表**，覆盖 **8 个业务域**：租户与组织、用户、产品使用行为、协作与内容、付费与订阅、客户支持、增长与实验、AI 使用与调查
- **50,000 用户、500 租户、12 个月数据**
- 数据集中包含真实数仓中常见的**数据质量问题**（如字段类型不一致、NULL 语义歧义、口径差异等），参赛者的 Agent 需要具备发现和处理这些问题的能力**数据集下载**：CloudWork 数据集（CSV，37 张表）— 云盘链接待发布（WIP）

3.2 必须完成项（Must-have）

参赛者需构建一个可交互的 **AI Data Analyst Agent**，展示以下全链路能力：

阶段零：多表 AI 知识库构建

面对 37 张表，自动构建一个结构化的数据知识库——不是表结构的简单罗列，而是一个 Agent 可查询、可推理的"数据大脑"。包括：

- **语义层**：每张表/字段的业务含义、数据粒度、更新频率
- **关系图谱**：表间关联关系、JOIN 键、关联类型
- **数据质量档案**：自动检测数据中的质量问题
- **查询经验库**：常见分析场景的推荐 JOIN 路径、已知问题和规避方案知识库应支持 Agent 在后续分析中**自动检索和引用**，并随分析经验不断完善。

阶段一至五：全链路分析能力

阶段	能力要求

Schema 理解与知识库	基于知识库，准确回答"这张表是什么粒度？""哪些表和用户留存分析相关？"等问题
关联发现	自动发现表间关联关系，理解一对多/多对多/时间窗口等复杂关联
查询生成	根据自然语言需求，参考知识库生成正确的多表 JOIN SQL
错误自修复	查询结果异常时，能自动检测、诊断原因、修复 SQL 并验证
深度分析	产出有业务价值的洞察，配合可视化和结构化报告

3.3 可选加分项（Good-to-have）

- **知识库持续学习**：Agent 每次分析后能自动沉淀经验，后续分析越来越准
- **知识图谱可视化**：表关系以可交互的 ER 图/知识图谱形式展示
- **数据血缘溯源**：用户可查看每个结论的数据来源、SQL 执行路径
- **AI 输出自我校验**：主动校验查询结果的合理性
- **多轮追问与上下文记忆**：支持基于前序分析结果的追问和下钻